A7_Regresión Lineal y A11. Regresión Lineal - Con interacción y A_12_Regresión Lineal - Análisis de los errores

Nallely Serna

2024-09-04

Analiza la base de datos de estatura y peso Download datos de estatura y pesode los hombres y mujeres en México y obten el mejor modelo de regresión para esos datos.

```r
# Cargar los datos de estatura y peso desde un archivo CSV
M = read.csv("Estatura-peso_HyM.csv")
head(M)  # Mostrar las primeras filas de los datos para verificar la
carga correcta
```

```
##   Estatura  Peso Sexo
## 1     1.61 72.21    H
## 2     1.61 65.71    H
## 3     1.70 75.08    H
## 4     1.65 68.55    H
## 5     1.72 70.77    H
## 6     1.63 77.18    H
```

```r
# Crear subconjuntos para hombres y mujeres
MM = subset(M, M$Sexo == "M")
MH = subset(M, M$Sexo == "H")

# Crear un dataframe con los datos de estatura y peso para hombres y
mujeres
M1 = data.frame(H_Estatura = MH$Estatura, H_Peso = MH$Peso, M_Estatura =
MM$Estatura, M_Peso = MM$Peso)
```

##La recta de mejor ajuste (Primera entrega)

##Obtén la matriz de correlación de los datos que se te proporcionan. Interpreta.

```r
# Obtener la matriz de correlación para las variables seleccionadas
correlacion = cor(M1)
correlacion
```

```
##               H_Estatura      H_Peso   M_Estatura     M_Peso
## H_Estatura 1.0000000000 0.846834792 0.0005540612 0.04724872
## H_Peso     0.8468347920 1.000000000 0.0035132246 0.02154907
## M_Estatura 0.0005540612 0.003513225 1.0000000000 0.52449621
## M_Peso     0.0472487231 0.021549075 0.5244962115 1.00000000
```

##Obtén medidas (media, desviación estándar, etc) que te ayuden a analizar los datos.

```r
# Calcular medidas estadísticas: mínimo, cuartiles, mediana, media,
máximo y desviación estándar
n = 4  # Número de variables
d = matrix(NA, ncol = 7, nrow = n)
for (i in 1:n) {
  d[i,] <- c(as.numeric(summary(M1[,i])), sd(M1[,i]))
}
m = as.data.frame(d)

row.names(m) = c("H-Estatura", "H-Peso", "M-Estatura", "M-Peso")
names(m) = c("Minimo", "Q1", "Mediana", "Media", "Q3", "Máximo", "Desv
Est")
m  # Mostrar el dataframe con las estadísticas

##            Minimo      Q1 Mediana     Media      Q3 Máximo   Desv Est
## H-Estatura   1.48  1.6100   1.650  1.653727  1.7000   1.80 0.06173088
## H-Peso      56.43 68.2575  72.975 72.857682 77.5225  90.49 6.90035408
## M-Estatura   1.44  1.5400   1.570  1.572955  1.6100   1.74 0.05036758
## M-Peso      37.39 49.3550  54.485 55.083409 59.7950  80.87 7.79278074
```

##Boxplots

```r
# Crear boxplots para estatura y peso según el sexo

boxplot(M$Peso ~ M$Sexo, ylab = "Peso", xlab = "", col = c("blue",
"pink"), names = c("Hombres", "Mujeres"), main = "Peso")
```

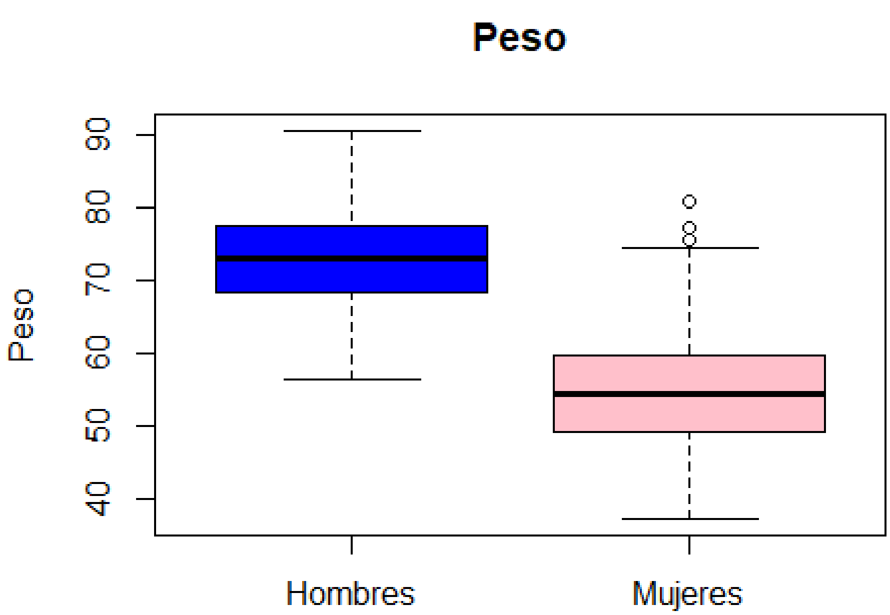

```r
boxplot(M$Estatura ~ M$Sexo, ylab = "Estatura", xlab = "", col =
c("blue", "pink"), names = c("Hombres", "Mujeres"), main = "Estatura")
```

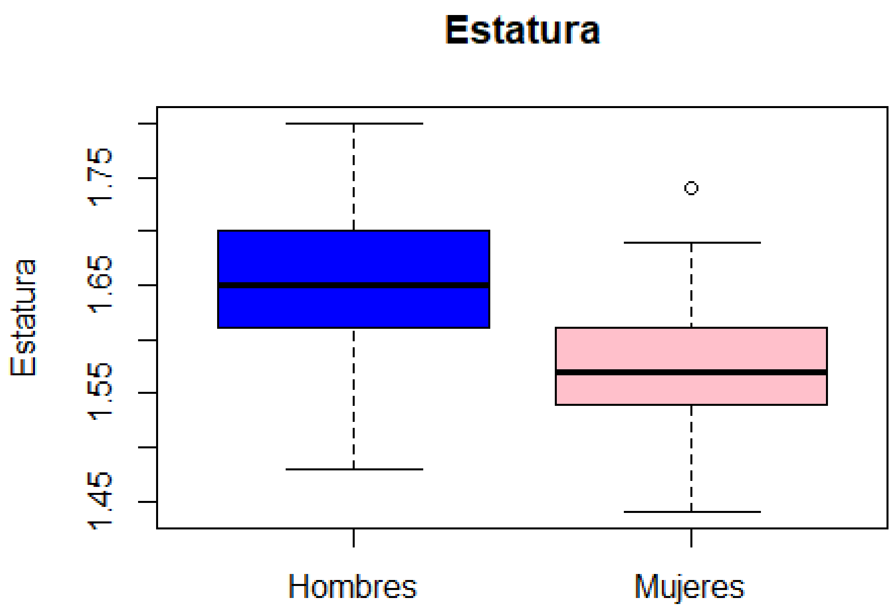

##Modelos de Regresión

Hipótesis: $H_0\colon \beta_1 = 0$ $H_1\colon \beta_1 n \neq 0$

Mujeres

```r
# Modelo de regresión lineal para mujeres (Peso -> Estatura)
Modelo1M = lm(Estatura ~ Peso, data = MM)
summary(Modelo1M)  # Resumen del modelo

##
## Call:
## lm(formula = Estatura ~ Peso, data = MM)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.11162 -0.02611 -0.00174  0.02806  0.12814
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1.3862212  0.0207336  66.859   <2e-16 ***
## Peso        0.0033900  0.0003727   9.096   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## Residual standard error: 0.04298 on 218 degrees of freedom
## Multiple R-squared:  0.2751, Adjusted R-squared:  0.2718
## F-statistic: 82.73 on 1 and 218 DF,  p-value: < 2.2e-16
```

```
summary(Modelo1M)
```

```
##
## Call:
## lm(formula = Estatura ~ Peso, data = MM)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.11162 -0.02611 -0.00174  0.02806  0.12814
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1.3862212  0.0207336  66.859   <2e-16 ***
## Peso        0.0033900  0.0003727   9.096   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.04298 on 218 degrees of freedom
## Multiple R-squared:  0.2751, Adjusted R-squared:  0.2718
## F-statistic: 82.73 on 1 and 218 DF,  p-value: < 2.2e-16
```

Hombres

```
# Modelo de regresión lineal para hombres (Peso -> Estatura)
Modelo1H = lm(Estatura ~ Peso, data = MH)
summary(Modelo1H)  # Resumen del modelo
```

```
##
## Call:
## lm(formula = Estatura ~ Peso, data = MH)
##
## Residuals:
##       Min        1Q    Median        3Q       Max
## -0.091473 -0.020942  0.001445  0.024020  0.082089
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1.1017704  0.0235832   46.72   <2e-16 ***
## Peso        0.0075758  0.0003223   23.51   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03291 on 218 degrees of freedom
## Multiple R-squared:  0.7171, Adjusted R-squared:  0.7158
## F-statistic: 552.7 on 1 and 218 DF,  p-value: < 2.2e-16
```

```r
# Verificar la significancia del modelo con un alfa de 0.03
anova(Modelo1M)  # Para mujeres

## Analysis of Variance Table
##
## Response: Estatura
##            Df  Sum Sq  Mean Sq F value    Pr(>F)
## Peso        1 0.15284 0.152838   82.73 < 2.2e-16 ***
## Residuals 218 0.40274 0.001847
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

anova(Modelo1H)  # Para hombres

## Analysis of Variance Table
##
## Response: Estatura
##            Df  Sum Sq Mean Sq F value    Pr(>F)
## Peso        1 0.59848 0.59848  552.67 < 2.2e-16 ***
## Residuals 218 0.23607 0.00108
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

# Verificación de la significancia de los coeficientes individuales (βî)
summary(Modelo1M)  # Verifica los p-valores para el modelo de mujeres

##
## Call:
## lm(formula = Estatura ~ Peso, data = MM)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.11162 -0.02611 -0.00174  0.02806  0.12814
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1.3862212  0.0207336  66.859   <2e-16 ***
## Peso        0.0033900  0.0003727   9.096   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.04298 on 218 degrees of freedom
## Multiple R-squared:  0.2751, Adjusted R-squared:  0.2718
## F-statistic: 82.73 on 1 and 218 DF,  p-value: < 2.2e-16

summary(Modelo1H)  # Verifica los p-valores para el modelo de hombres

##
## Call:
## lm(formula = Estatura ~ Peso, data = MH)
##
## Residuals:
```

```
##        Min        1Q    Median        3Q       Max
## -0.091473 -0.020942  0.001445  0.024020  0.082089
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1.1017704  0.0235832   46.72   <2e-16 ***
## Peso        0.0075758  0.0003223   23.51   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03291 on 218 degrees of freedom
## Multiple R-squared:  0.7171, Adjusted R-squared:  0.7158
## F-statistic: 552.7 on 1 and 218 DF,  p-value: < 2.2e-16
```

##Dibuja el diagrama de dispersión de los datos y la recta de mejor ajuste.

```
# Diagrama de dispersión y recta de mejor ajuste para mujeres
plot(MM$Estatura, MM$Peso, main = "Estatura vs Peso (Mujeres)", xlab =
"Estatura", ylab = "Peso", pch = 19, col = "pink")
abline(Modelo1M, col = "blue")
```

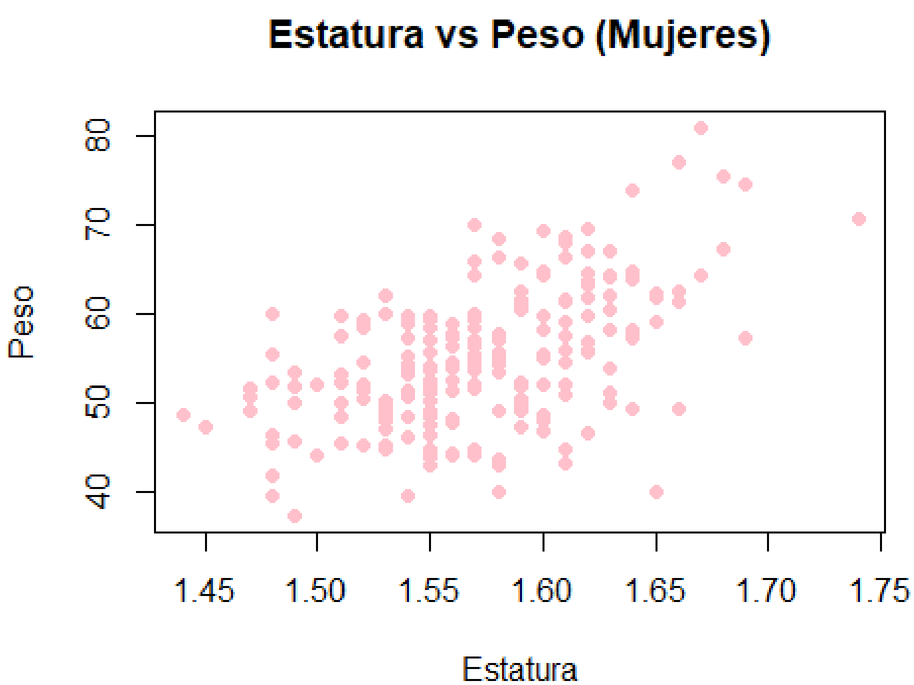


```
# Diagrama de dispersión y recta de mejor ajuste para hombres
plot(MH$Estatura, MH$Peso, main = "Estatura vs Peso (Hombres)", xlab =
"Estatura", ylab = "Peso", pch = 19, col = "blue")
abline(Modelo1H, col = "red")
```

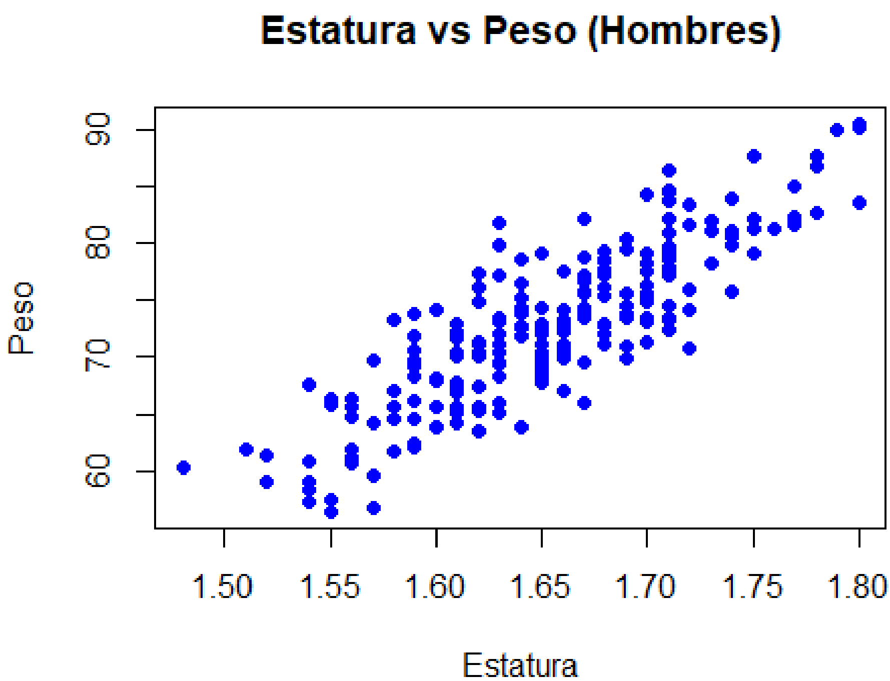

##Modelo de Regresión con Sexo

```
Modelo2 = lm(Estatura ~ Peso + Sexo, M)
Modelo2

##
## Call:
## lm(formula = Estatura ~ Peso + Sexo, data = M)
##
## Coefficients:
## (Intercept)         Peso       SexoM
##     1.27271      0.00523      0.01218
```

##Interpretación de los Coeficientes:

A 0.05 sí es significativo y los modelos quedarían:

```
b0 = Modelo2$coefficients[1]
b1 = Modelo2$coefficients[2]
b2 = Modelo2$coefficients[3]

Ym = function(x){b0+b2+b1*x}
Yh = function(x){b0+b1*x}

colores = c("lightblue", "pink2")
```

```
plot(M$Estatura, M$Peso,  col=colores[factor(M$Sexo)], pch=19,
ylab="Peso", xlab="Estatura", main="Relación peso vs Estatura")

x = seq(1.40, 1.80, 0.1)
lines(x, Ym(x), col="pink2", lwd=2)
lines(x, Yh(x), col="lightblue", lwd=2)
```

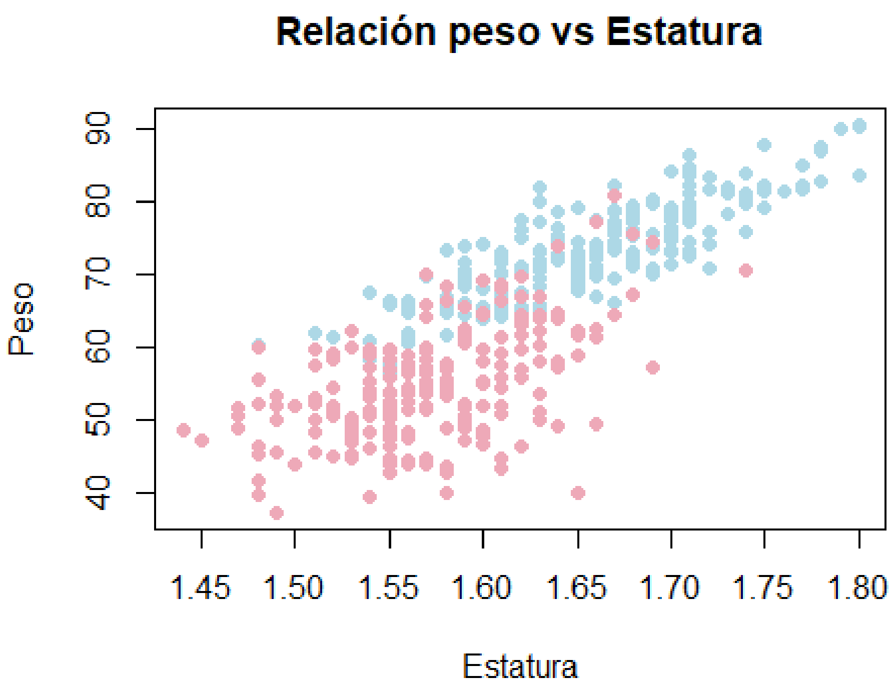

$\hat{\beta}0$ (Intercepto): Representa la estatura esperada cuando el peso es cero, ajustado por el sexo. $\hat{\beta}1$ (Pendiente): Representa el cambio en la estatura por unidad de cambio en el peso, ajustado por el sexo. $\hat{\beta}2$ (Efecto del Sexo): Ajusta la relación de estatura y peso según el sexo, diferenciando entre hombres y mujeres.

```
# Crear el modelo de regresión lineal
Modelo = lm(Peso ~ Estatura + Sexo + Estatura:Sexo, data = M)
summary(Modelo)  # Resumen del modelo

##
## Call:
## lm(formula = Peso ~ Estatura + Sexo + Estatura:Sexo, data = M)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.3256  -3.1107   0.0204   3.2691  17.9114
##
## Coefficients:
##                 Estimate Std. Error t value Pr(>|t|)
```

```
## (Intercept)     -83.685      9.735  -8.597   <2e-16 ***
## Estatura         94.660      5.882  16.092   <2e-16 ***
## SexoM            11.124     14.950   0.744    0.457    
## Estatura:SexoM  -13.511      9.305  -1.452    0.147    
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## 
## Residual standard error: 5.374 on 436 degrees of freedom
## Multiple R-squared:  0.7847, Adjusted R-squared:  0.7832 
## F-statistic: 529.7 on 3 and 436 DF,  p-value: < 2.2e-16
```

```
# Verificación de la significancia global del modelo con un alfa de 0.03
anova(Modelo)
```

```
## Analysis of Variance Table
## 
## Response: Peso
##                 Df Sum Sq Mean Sq   F value Pr(>F)    
## Estatura         1  37731   37731 1306.5938 <2e-16 ***
## Sexo             1   8097    8097  280.3892 <2e-16 ***
## Estatura:Sexo    1     61      61    2.1085 0.1472    
## Residuals      436  12590      29                     
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# Verificación de la significancia de los coeficientes individuales (βî)
summary(Modelo)
```

```
## 
## Call:
## lm(formula = Peso ~ Estatura + Sexo + Estatura:Sexo, data = M)
## 
## Residuals:
##      Min       1Q   Median       3Q      Max 
## -21.3256  -3.1107   0.0204   3.2691  17.9114 
## 
## Coefficients:
##                 Estimate Std. Error t value Pr(>|t|)    
## (Intercept)     -83.685      9.735  -8.597   <2e-16 ***
## Estatura         94.660      5.882  16.092   <2e-16 ***
## SexoM            11.124     14.950   0.744    0.457    
## Estatura:SexoM  -13.511      9.305  -1.452    0.147    
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## 
## Residual standard error: 5.374 on 436 degrees of freedom
## Multiple R-squared:  0.7847, Adjusted R-squared:  0.7832 
## F-statistic: 529.7 on 3 and 436 DF,  p-value: < 2.2e-16
```

```r
# Obtener el R-squared del modelo
R_squared = summary(Modelo)$r.squared
R_squared  # Mostrar el porcentaje de variación explicada por el modelo

## [1] 0.7847011

# Modelo de regresión lineal con interacción Estatura*Sexo
Modelo_interaccion = lm(Peso ~ Estatura * Sexo, data = M)
summary(Modelo_interaccion)  # Resumen del modelo

##
## Call:
## lm(formula = Peso ~ Estatura * Sexo, data = M)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.3256  -3.1107   0.0204   3.2691  17.9114
##
## Coefficients:
##                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)      -83.685      9.735  -8.597   <2e-16 ***
## Estatura          94.660      5.882  16.092   <2e-16 ***
## SexoM             11.124     14.950   0.744    0.457
## Estatura:SexoM   -13.511      9.305  -1.452    0.147
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.374 on 436 degrees of freedom
## Multiple R-squared:  0.7847, Adjusted R-squared:  0.7832
## F-statistic: 529.7 on 3 and 436 DF,  p-value: < 2.2e-16

# Verificación de la significancia global del modelo con un alfa de 0.03
anova(Modelo_interaccion)

## Analysis of Variance Table
##
## Response: Peso
##                Df Sum Sq Mean Sq   F value Pr(>F)
## Estatura        1  37731   37731 1306.5938 <2e-16 ***
## Sexo            1   8097    8097  280.3892 <2e-16 ***
## Estatura:Sexo   1     61      61    2.1085 0.1472
## Residuals     436  12590      29
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

# Verificación de la significancia de los coeficientes individuales (βî)
summary(Modelo_interaccion)

##
## Call:
## lm(formula = Peso ~ Estatura * Sexo, data = M)
##
```

```
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.3256  -3.1107   0.0204   3.2691  17.9114
##
## Coefficients:
##                Estimate Std. Error t value Pr(>|t|)
## (Intercept)     -83.685      9.735  -8.597   <2e-16 ***
## Estatura         94.660      5.882  16.092   <2e-16 ***
## SexoM            11.124     14.950   0.744    0.457
## Estatura:SexoM  -13.511      9.305  -1.452    0.147
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.374 on 436 degrees of freedom
## Multiple R-squared:  0.7847, Adjusted R-squared:  0.7832
## F-statistic: 529.7 on 3 and 436 DF,  p-value: < 2.2e-16
```

```
# Obtener el R-squared del modelo
R_squared = summary(Modelo_interaccion)$r.squared
R_squared  # Mostrar el porcentaje de variación explicada por el modelo
```

```
## [1] 0.7847011
```

```
# Coeficientes del modelo
b0_interaccion = Modelo_interaccion$coefficients[1]
b1_interaccion = Modelo_interaccion$coefficients[2]
b2_interaccion = Modelo_interaccion$coefficients[3]
b3_interaccion = Modelo_interaccion$coefficients[4]

# Funciones para la recta de mejor ajuste
Ym_interaccion = function(x){b0_interaccion + b2_interaccion +
(b1_interaccion + b3_interaccion) * x}
Yh_interaccion = function(x){b0_interaccion + b1_interaccion * x}

# Graficar la relación entre Estatura y Peso
colores = c("#66BD63", "#FDAE61")
plot(M$Estatura, M$Peso, col = colores[factor(M$Sexo)], pch = 19, ylab =
"Peso", xlab = "Estatura", main = "Relación entre estatura y peso")

x = seq(min(M$Estatura), max(M$Estatura), length.out = 100)
lines(x, Ym_interaccion(x), col = "#FDAE61", lwd = 3)
lines(x, Yh_interaccion(x), col = "#66BD63", lwd = 3)

legend("topleft", legend = c("Hombre", "Mujer"), pch = 19, col =
c("#66BD63", "#FDAE61"))
```

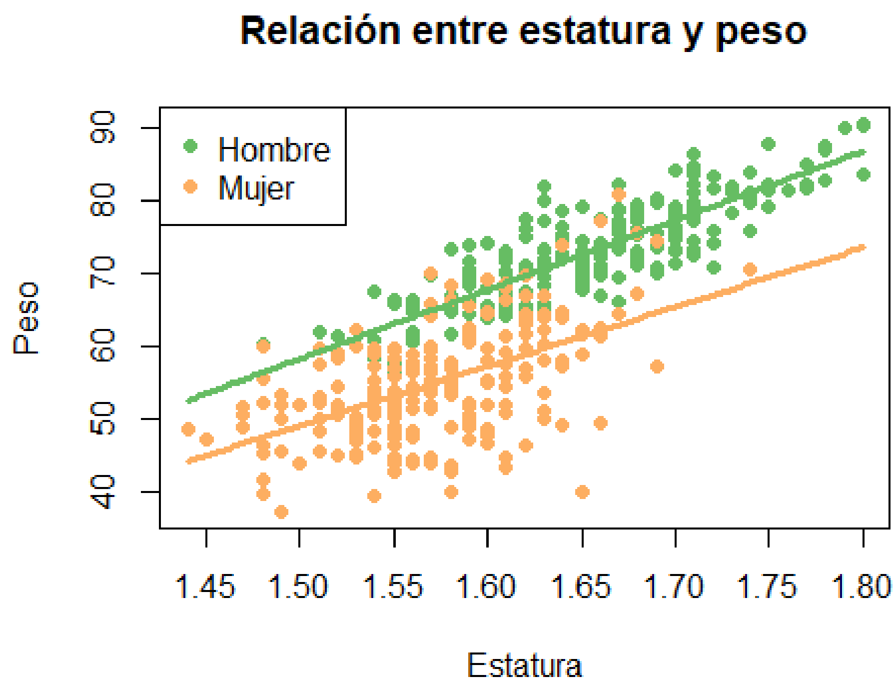


```
# Interpretación de los coeficientes
b0_interaccion   # β0̂ (Intercepto)

## (Intercept)
##   -83.68454

b1_interaccion   # β1̂ (Pendiente para Estatura)

## Estatura
## 94.66024

b2_interaccion   # β2̂ (Efecto del Sexo)

##    SexoM
## 11.12409

b3_interaccion   # β3̂ (Interacción Estatura*Sexo)

## Estatura:SexoM
##      -13.51113
```

Significación del modelo: Si el valor p del ANOVA es menor que 0.03, el modelo es significativo, lo que indica que la estatura (junto con el sexo) es un buen predictor del peso.

Significación individual Si el valor p para el coeficiente de Estatura es menor que 0.03, podemos afirmar que la estatura tiene un impacto significativo en el peso.

Coeficiente de determinación (R^2): Un R^2 cercano a 1 sugiere que el modelo explica una gran proporción de la variabilidad en el peso, mientras que un valor más bajo indicaría un modelo menos eficaz.

#Análisis de los Modelos Modelo Simple (Peso vs. Estatura):

Este modelo no toma en cuenta las diferencias entre hombres y mujeres. Es simple y directo, pero puede no capturar la variabilidad entre sexos.

R2 ajustado bajo comparado con los otros modelos, lo que sugiere que no explica toda la variabilidad en los datos.

Modelo con el Efecto del Sexo (Peso vs. Estatura + Sexo):

Incluye una variable categórica para el sexo, lo que permite capturar diferencias en el peso promedio entre hombres y mujeres.

Mejora en el R2ajustado y la significancia de los coeficientes, lo que indica un mejor ajuste que el modelo simple.

Modelo con Interacción (Peso vs. Estatura * Sexo):

Este modelo permite que la relación entre la estatura y el peso varíe según el sexo, lo que podría ser más realista si la pendiente de la relación peso-estatura difiere entre hombres y mujeres.

Presenta el R2 ajustado más alto, lo que indica que explica mejor la variabilidad en el peso. Todos los coeficientes son significativos, y la interacción sugiere que la estatura afecta al peso de manera diferente para hombres y mujeres.

El modelo con interacción (Peso vs. Estatura * Sexo) parece ser el más apropiado. Este modelo no solo tiene el mejor ajuste estadístico (con un R2 ajustado más alto), sino que también considera cómo la relación entre estatura y peso puede variar entre hombres y mujeres. La significancia estadística de todos los términos en este modelo apoya su uso, y aunque es más complejo que los otros modelos, esta complejidad se justifica por su capacidad para capturar diferencias clave entre los sexos.

##12. Regresión Lineal - Análisis de los errores

```
library(nortest)
ad.test(Modelo$residuals)  # Prueba de Anderson-Darling

##
##  Anderson-Darling normality test
##
## data:  Modelo$residuals
## A = 0.8138, p-value = 0.03516
```

```
# Gráficos de normalidad
qqnorm(Modelo$residuals)
qqline(Modelo$residuals)
```

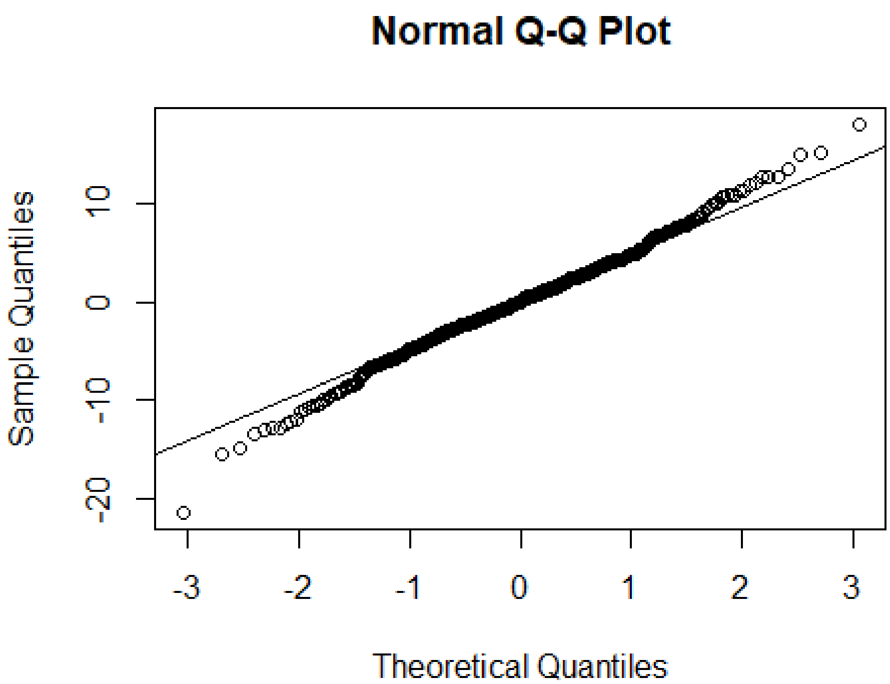


```
hist(Modelo$residuals, freq=FALSE)
lines(density(Modelo$residuals), col="red")
curve(dnorm(x, mean=mean(Modelo$residuals), sd=sd(Modelo$residuals)),
from=-6, to=6, add=TRUE, col="blue", lwd=2)
```

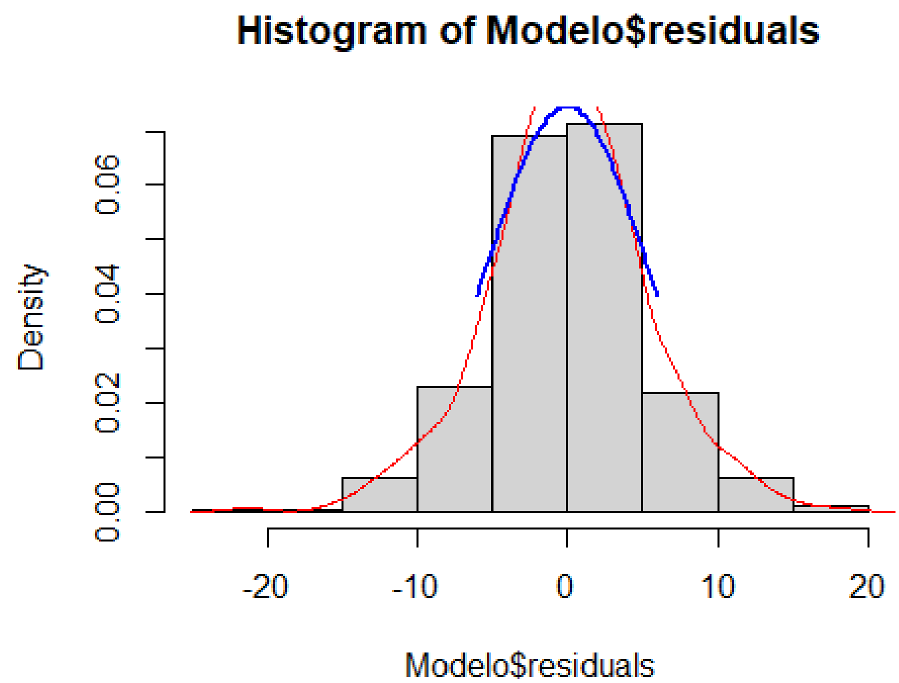


```
t.test(Modelo$residuals, mu = 0)

##
##  One Sample t-test
##
## data:  Modelo$residuals
## t = 8.3074e-16, df = 439, p-value = 1
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
##  -0.5017741  0.5017741
## sample estimates:
##    mean of x
## 2.120936e-16

library(lmtest)
bptest(Modelo)

##
##  studentized Breusch-Pagan test
##
## data:  Modelo
## BP = 59.211, df = 3, p-value = 8.667e-13

dwtest(Modelo)

##
##  Durbin-Watson test
##
```

```
## data:  Modelo
## DW = 1.8646, p-value = 0.07113
## alternative hypothesis: true autocorrelation is greater than 0
```

```
bgtest(Modelo)
```

```
##
##  Breusch-Godfrey test for serial correlation of order up to 1
##
## data:  Modelo
## LM test = 1.3453, df = 1, p-value = 0.2461
```

```
plot(Modelo$fitted.values, Modelo$residuals)
abline(h=0, col="blue")
```

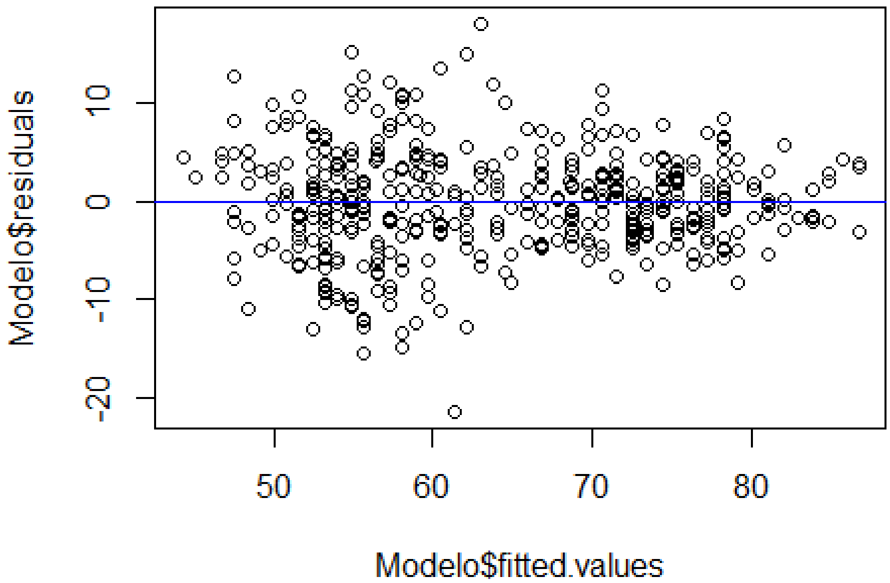


```
# Para mujeres
ModeloM = lm(Peso ~ Estatura, data = MM)
# Para hombres
ModeloH = lm(Peso ~ Estatura, data = MH)

# Obtener los intervalos de predicción para mujeres
IpM = predict(ModeloM, interval = "prediction", level = 0.97)
```

```
## Warning in predict.lm(ModeloM, interval = "prediction", level = 0.97):
predictions on current data refer to _future_ responses
```

```
# Obtener los intervalos de confianza para mujeres
IcM = predict(ModeloM, interval = "confidence", level = 0.97)
```

```r
# Combinar los datos con los intervalos de predicción y confianza
datosM = cbind(MM, lwr_pred = IpM[, "lwr"], upr_pred = IpM[, "upr"],
               fit_pred = IpM[, "fit"], lwr_conf = IcM[, "lwr"],
               upr_conf = IcM[, "upr"], fit_conf = IcM[, "fit"])

# Obtener los intervalos de predicción para hombres
IpH = predict(ModeloH, interval = "prediction", level = 0.97)

## Warning in predict.lm(ModeloH, interval = "prediction", level = 0.97):
predictions on current data refer to _future_ responses

# Obtener los intervalos de confianza para hombres
IcH = predict(ModeloH, interval = "confidence", level = 0.97)

# Combinar los datos con los intervalos de predicción y confianza
datosH = cbind(MH, lwr_pred = IpH[, "lwr"], upr_pred = IpH[, "upr"],
               fit_pred = IpH[, "fit"], lwr_conf = IcH[, "lwr"],
               upr_conf = IcH[, "upr"], fit_conf = IcH[, "fit"])

# Gráfico para Mujeres
plot(MM$Estatura, MM$Peso, main = "Intervalos de Predicción y Confianza
(Mujeres)",
     xlab = "Estatura", ylab = "Peso", pch = 19, col = "pink")
lines(MM$Estatura, datosM$lwr_pred, col = "red", lty = 2)  # Límite
inferior predicción
lines(MM$Estatura, datosM$upr_pred, col = "red", lty = 2)  # Límite
superior predicción
lines(MM$Estatura, datosM$fit_pred, col = "blue")          # Estimación
(predicción)
lines(MM$Estatura, datosM$lwr_conf, col = "green", lty = 3)  # Límite
inferior confianza
lines(MM$Estatura, datosM$upr_conf, col = "green", lty = 3)  # Límite
superior confianza
```

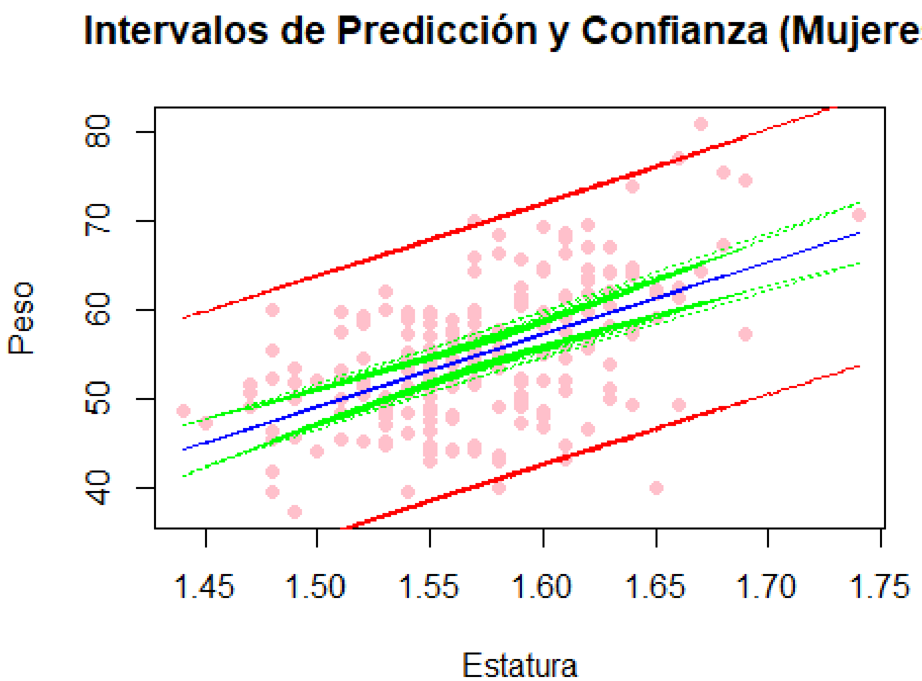


```
# Gráfico para Hombres
plot(MH$Estatura, MH$Peso, main = "Intervalos de Predicción y Confianza
(Hombres)",
     xlab = "Estatura", ylab = "Peso", pch = 19, col = "blue")
lines(MH$Estatura, datosH$lwr_pred, col = "red", lty = 2)  # Límite
inferior predicción
lines(MH$Estatura, datosH$upr_pred, col = "red", lty = 2)  # Límite
superior predicción
lines(MH$Estatura, datosH$fit_pred, col = "blue")          # Estimación
(predicción)
lines(MH$Estatura, datosH$lwr_conf, col = "green", lty = 3)  # Límite
inferior confianza
lines(MH$Estatura, datosH$upr_conf, col = "green", lty = 3)  # Límite
superior confianza
```

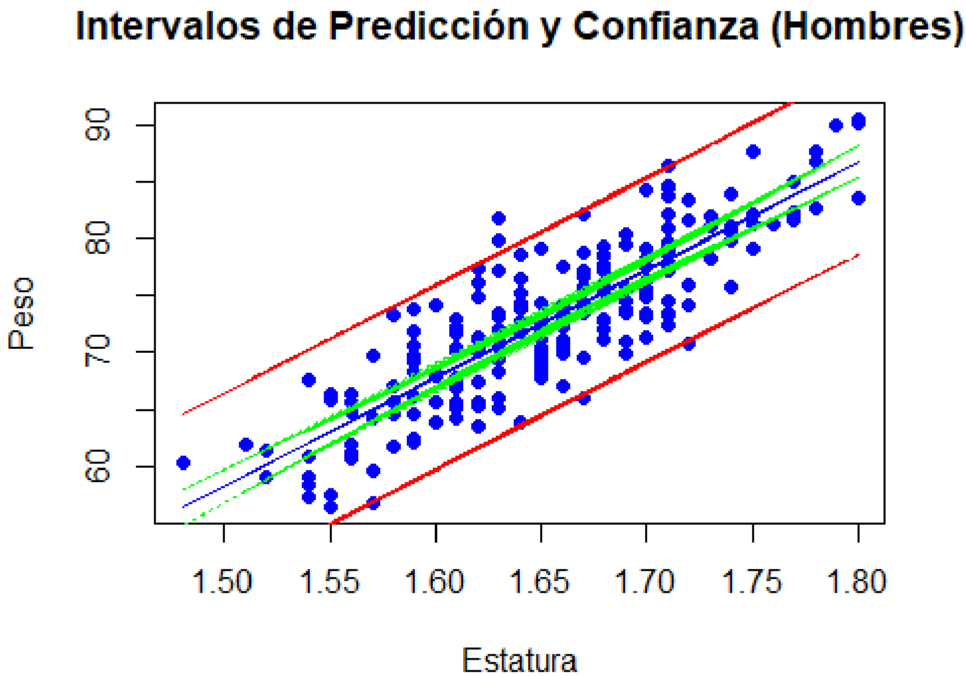

#1. Anderson-Darling Normality Test

Resultado: A = 0.8138, p-value = 0.03516

Interpretación: Este test evalúa si los residuos siguen una distribución normal. Un p-valor bajo (como 0.03516) sugiere que podemos rechazar la hipótesis nula de normalidad de los residuos al nivel de significancia del 5%. Esto indica que los residuos no siguen una distribución normal, lo cual puede afectar la fiabilidad de las inferencias basadas en el modelo.

#2. One Sample t-test Resultado: t = 8.3074e-16, df = 439, p-value = 1, CI = (-0.5017741, 0.5017741)

Interpretación: Este test evalúa si la media de los residuos es significativamente diferente de cero. El p-valor de 1 indica que no hay evidencia suficiente para rechazar la hipótesis nula de que la media de los residuos es cero. Esto es favorable, ya que sugiere que no hay sesgo en los residuos y que, en promedio, los errores de predicción del modelo se centran en torno a cero.

#3. Studentized Breusch-Pagan Test

Resultado: BP = 59.211, df = 3, p-value = 8.667e-13

Interpretación: Este test evalúa la homocedasticidad, es decir, si la varianza de los residuos es constante a lo largo de los valores predichos. Un p-valor extremadamente bajo (8.667e-13) sugiere que podemos rechazar la hipótesis nula de homocedasticidad. Esto implica que hay heterocedasticidad en los residuos, lo que significa que la variabilidad de los errores de predicción cambia con el valor de las predicciones, lo que puede afectar la precisión de los intervalos de confianza y de predicción.

#4. Durbin-Watson Test

Resultado: DW = 1.8646, p-value = 0.07113

Interpretación: Este test evalúa la independencia de los residuos, específicamente la autocorrelación de primer orden. Un valor de DW cercano a 2 sugiere poca autocorrelación. El p-valor de 0.07113 indica que no podemos rechazar la hipótesis nula de que no hay autocorrelación positiva, lo cual es favorable para el modelo, aunque el resultado está cerca del límite de significancia comúnmente usado (0.05).

#5. Breusch-Godfrey Test for Serial Correlation

Resultado: LM test = 1.3453, df = 1, p-value = 0.2461

Interpretación: Este test también evalúa la autocorrelación en los residuos, pero permite detectar autocorrelación de mayor orden. El p-valor de 0.2461 sugiere que no hay evidencia suficiente para rechazar la hipótesis nula de que no hay autocorrelación en los residuos, lo cual es un buen indicador de que los residuos son independientes entre sí.

#6. Advertencia en predict.lm:

Advertencia: “predictions on current data refer to future responses”

Interpretación: Esta advertencia indica que las predicciones realizadas con el modelo asumen que los datos actuales son representativos de respuestas futuras, lo cual es una característica estándar en la predicción y no representa un problema en sí misma. Sin embargo, es un recordatorio de que se deben tener en cuenta las suposiciones del modelo cuando se utilizan estas predicciones.